

第7章 参数估计





7.1 点估计

设有一个统计总体，总体的分布函数为：

$F(x, \theta)$ ，其中 θ 为未知参数 (θ 可以是向量)。

现从该总体抽样，得样本 X_1, X_2, \dots, X_n

要依据该样本对参数 θ 作出估计，或估计 θ 某个已知函数 $g(\theta)$ 。

这类问题称为**参数估计**。

参数估计两种方法：

{	矩方法
	最大似然估计



一、矩估计

原理：用样本矩代替相应的总体矩，（大数定律）

回忆矩的记法：

原点矩

中心矩

样本k阶矩

$$a_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad (k=1,2,\dots)$$

$$m_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k \quad (k=1,2,\dots)$$

总体k阶矩

$$\mu_k = E(X^k)$$

$$d_k = E[X - E(X)]^k$$

在k阶矩存在的情况下，大数定律 $a_k \xrightarrow{P} \mu_k$, $m_k \xrightarrow{P} d_k$ 。

$$\bar{X} \sim E(X) \quad S^2 \sim D(X)$$



一、矩估计

设 $\theta = (\theta_1, \theta_2, \dots, \theta_k)$ $E(X) = \int_{-\infty}^{+\infty} xf(x, \theta)dx = g_1(\theta_1, \theta_2, \dots, \theta_k)$

即: $\bar{X} \simeq g_1(\theta_1, \theta_2, \dots, \theta_k)$

对于 k 个未知数, $E(X^j) = \int_{-\infty}^{+\infty} x^j f(x, \theta)dx = g_j(\theta_1, \theta_2, \dots, \theta_k)$

$$\Rightarrow g_j(\theta_1, \theta_2, \dots, \theta_k) = a_j \quad j=1, 2, \dots, k$$

从这 k 个方程中解出 $\theta_1, \theta_2, \dots, \theta_k$ 的估计值: $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$

$$\hat{\theta}_i = \hat{\theta}_i(X_1, X_2, \dots, X_n)$$

θ_1 真正的总体参数, 未知常数, 非随机。

$\hat{\theta}_1$ 由样本对参数做的一个估计, 是统计量, 与样本有关, 随机性。

注意: 未知常数 \neq 随机变量



总体 $X \sim F(x, \theta)$, $E(X) = \mu$; 估 $\theta_1 = \mu$ $\theta_2 = \sigma^2$

$\hat{\mu} = \bar{X}$ 用样本一阶矩代替总体一阶矩。

估 σ^2 : $D(X) = E[X - E(X)]^2$ 总体二阶中心距需用样本二阶中心距代替

$$\hat{\sigma}^2 = \frac{1}{n} \sum_n (X_i - \bar{X})^2$$

矩估计: { 优点: 简单, 不需要事先知道什么分布。
缺点: 矩估计量不唯一。

其主要原因在于建立矩法方程时, 选取那些总体矩用相应样本矩代替带有一定的随意性。



例1: $X \sim U(0, \theta)$ 估 θ

解

算一阶矩: $E(X) = \int_{-\infty}^{+\infty} x \frac{1}{\theta} I_{(0, \theta)}(x) dx = \frac{1}{\theta} \int_0^{\theta} x dx = \frac{\theta}{2}$



\bar{X} 用样本距代替

$$\Rightarrow \hat{\theta} = 2\bar{X}$$

例2: $X \sim U(\theta_1, \theta_2)$, 算一阶矩和二阶距。

解

$$E(X) = \frac{\theta_1 + \theta_2}{2} \quad D(X) = \frac{(\theta_2 - \theta_1)^2}{12}$$

$$\begin{cases} \frac{\theta_1 + \theta_2}{2} = \bar{X} \\ \frac{(\theta_2 - \theta_1)^2}{12} = m_2 \end{cases} \Rightarrow \begin{cases} \theta_1 + \theta_2 = 2\bar{X} \\ \theta_2 - \theta_1 = 2\sqrt{3m_2} \end{cases} \Rightarrow \theta_1, \theta_2 = \bar{X} \pm \sqrt{\frac{3}{n} \sum_n (X_i - \bar{X})^2}$$



例2: $X \sim P(\lambda)$

解 $E(X) = \lambda \Rightarrow \hat{\lambda} = \bar{X}$

$$D(X) = \lambda \Rightarrow \hat{\lambda} = m_2$$

不唯一时，选择哪个估计量好？

原则：从低到高，能用低阶矩处理的就不用高阶矩。

矩估计的步骤：

- ① 计算总体前k阶矩，找出这些矩与参数 $\theta = (\theta_1, \theta_2, \dots, \theta_k)$ 的关系式；
- ② 用样本矩代替总体矩，解这k个方程组。



二、最大似然估计 (MLE)

什么是似然函数？

设总体 X 为连续型随机变量，其分布律为 $f(x, \theta)$ ；

设总体 X 为离散型随机变量，其分布律为： $P(X = x) = p_i(\theta)$ 记为 $p(x_i, \theta)$ 或 $p(x, \theta)$

$$x = x_i, i = 1, 2, \dots, n$$

X_1, X_2, \dots, X_n 是来自总体 X 的样本， $(X_1 \dots X_n)$ 服从：

$$\prod_{i=1}^n f(x_i, \theta) \text{ 或 } \prod_{i=1}^n p(x_i, \theta)$$

$$\text{记: } L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) \quad L(x, \theta) = \prod_{i=1}^n f(x_i; \theta)$$

给定 θ ， L 称为 $(X_1 \dots X_n)$ 的密度函数 联合密度函数；

给定 x ， L 作为 $(\theta_1, \theta_2, \dots, \theta_k)$ 的函数，称为似然函数。

密度函数和似
然函数的区别



二、最大似然估计 (MLE)

最大似然法的基本思想：

假定一个随机试验E有若干个可能的结果 A_1, A_2, \dots, A_n 如果只进行了一次试验，而 A_k 出现了，那么有理由认为试验的条件对结果 A_k 的出现最有利，即试验E出现结果中的 A_k 概率最大。

已知： $x = (x_1, \dots, x_n)$,求 $\theta = (\theta_1, \theta_2, \dots, \theta_k)$ 使 $L(x, \theta) = \max$ 。

二、最大似然估计 (MLE)

已知： $x = (x_1, \dots, x_n)$, 求 $\theta = (\theta_1, \theta_2, \dots, \theta_k)$ 使 $L(x, \theta) = \max$ 。

求似然函数 $L(\theta)$ 的最大值点，可以应用微积分中的技巧。由于 $\ln(x)$ 是 x 的增函数， $\ln L(\theta)$ 与 $L(\theta)$ 在 θ 的同一值处达到它的最大值，假定 θ 是一实数，且 $\ln L(\theta)$ 是 θ 的一个可微函数。通过求解方程：

$$\frac{d \ln L(\theta)}{d \theta} = 0$$

可以得到 θ 的最大似然估计。

最大似然估计的步骤：

- ① 写出似然函数 $L(\theta)$;
- ② 取自然对数 $\ln L(\theta)$;
- ③ 令： $\frac{\partial \ln L(\theta)}{\partial \theta_i} = 0$, 求 $\hat{\theta}_i$ 。



例1: 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 未知。 x_1, \dots, x_n 是来自 X 的样本值, 试求 μ, σ^2 的最大似然估计量。

解 X 的概率密度为 $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$, $-\infty < x < \infty$

$$\text{似然函数为 } L(x, \theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} = (2\pi)^{-n/2} (\sigma^2)^{-n/2} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right]$$

$$\text{于是 } \ln L(x, \theta) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

$$\ln L(x, \theta) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \theta_2 - \frac{1}{2\theta_2} \sum_{i=1}^n (x_i - \theta_1)^2$$

$$\frac{\partial \ln L(x, \theta)}{\partial \theta_1} = \frac{1}{\theta_2} \left(\sum_{i=1}^n x_i - n\theta_1 \right) = 0$$

μ, σ^2 的最大似然估计量为:

$$\frac{\partial \ln L(x, \theta)}{\partial \theta_2} = -\frac{n}{2\theta_2} + \frac{1}{2\theta_2^2} \sum_{i=1}^n (x_i - \theta_1)^2 = 0$$

$$\mu = \bar{X},$$

$$\text{解得 } \theta_1 = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \quad \theta_2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$



例: $X \sim U(0, \theta)$ 求 $\hat{\theta}$

解 $X \sim f(x, \theta) = \frac{1}{\theta} I_{(0, \theta)}(x)$

$$L(x, \theta) = \frac{1}{\theta} \prod_{i=1}^n I_{(0, \theta)}(x_i) \quad \text{似然函数, } \theta \text{ 未知, } x \text{ 已知, 固定 } x \text{ 求 } \theta \text{。}$$

$$0 < x_1 < \theta, 0 < x_1 < \theta, \dots$$

$$= \frac{1}{\theta^n} \prod_{i=1}^n I_{(x_{(n)}, \infty)}(\theta)$$

而 $\frac{1}{\theta^n}$ 是 θ 的减函数, 即: $\theta = x_{(n)}$ 时最大。

$$\Rightarrow \hat{\theta} = X_{(n)} = \max\{X_1, X_2, \dots, X_n\}$$



对于离散型随机变量（以二项分布为例）

$$P(X = k) = C_N^k p^k (1-p)^{N-k} \quad k = 0, 1, 2, \dots$$

↓
 x_i , $x_i = 0, 1, 2, \dots, n$ 样本数

↘ 用大写字母以与样本数做区分。

$$\text{似然函数 } L(x, \theta) = \prod_{i=1}^n P(X = x_i) = \prod_{i=1}^n \left\{ C_N^{x_i} p^{x_i} (1-p)^{N-x_i} \right\} = \left(\prod_{i=1}^n C_N^{x_i} \right) p^{\sum_{i=1}^n x_i} (1-p)^{Nn - \sum_{i=1}^n x_i}$$

给定 $x = (x_1, x_2, \dots, x_n)$, 求 $\theta = (\theta_1, \theta_2, \dots, \theta_k)$ 使 $L(x_1, \dots, x_n; \theta_1, \dots, \theta_k) = \max$

$$\ln L(x, p) = C + (\sum x_i) \ln p + (Nn - \sum_n x_i) \ln(1-p)$$

$$\frac{d \ln L}{dp} = \frac{1}{p} (\sum x_i) - \frac{(Nn - \sum x_i)}{1-p} = 0$$

$$\frac{1}{p} \overline{nx} = \frac{Nn - \overline{nx}}{1-p} \Rightarrow p = \frac{\overline{x}}{N}$$

$$\therefore \hat{p} = \frac{\overline{X}}{N}$$



一、无偏性

估计量是随机变量，对于不同的样本值会得到不同的估计值。我们希望估计值在未知参数真值附近摆动，而它的期望值等于未知参数的真值。这就导致无偏性这个标准。

设 $\hat{\theta}(X_1, \dots, X_n)$ 是未知参数 θ 的估计量，若 $E(\hat{\theta}) = \theta$ ，则称 $\hat{\theta}$ 为 θ 的无偏估计。

例1： $\hat{\mu} = \bar{X}$ 是否无偏？

解

$$E(\bar{X}) = E\left(\sum_{i=1}^n X_i / n\right) = \frac{1}{n} n E(X) = \mu$$

所以 \bar{X} 是总体均值的无偏估计。



总体均值还有无别的无偏估计？

$$\hat{\mu}_1 = \sum_{i=1}^n W_i X_i \quad W_i \geq 0, \quad \sum W_i = 1$$

$$E(\hat{\mu}_1) = \sum_{i=1}^n W_i E(X_i) = \mu \sum W_i = \mu$$

所以加权平均也是无偏估计，即无偏估计不唯一。

$$m_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \hat{\sigma}^2 = m_2 \quad \text{那么 } m_2 \text{ 是否无偏?}$$

$$\sum (X_i - \bar{X})^2 = \sum [(X_i - \mu) + (\bar{X} - \mu)]^2 = \sum (X_i - \mu)^2 + n(\bar{X} - \mu)^2 - 2(\bar{X} - \mu) \sum_n (X_i - \mu)$$

$$E\left[\sum (X_i - \mu)^2\right] = n\sigma^2 \quad E(\bar{X} - \mu)^2 = \frac{1}{n}\sigma^2 \quad \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$\sum (X_i - \mu) = \sum X_i - n\mu = n\bar{X} - n\mu = n(\bar{X} - \mu)$$

$$\therefore E(m_2) = \frac{1}{n}(n\sigma^2 + \sigma^2 - 2\sigma^2) = \frac{n-1}{n}\sigma^2 < \sigma^2 \quad \text{系统偏小}$$



对 m_2 做修正: $S^2 = \frac{n}{n-1} m_2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$

$E(S^2) = \sigma^2$ 即样本方差是 m_2 的无偏估计。

注意: 不是 “ S 是 σ 的无偏估计”。 $E(S) \neq \sigma$

例2: $X \sim U(0, \theta)$ $\hat{\theta}_M = 2\bar{X}$ $\hat{\theta}_L = X_{(n)}$

解 $E(\hat{\theta}_M) = 2E(\bar{X}) = 2 \cdot \frac{\theta}{2} = \theta$ 无偏

计算 $E(X_{(n)})$ 要先计算 X_1, X_2, \dots, X_n 最大值的分布。按定义求最大值的分布函数:

$$P(X_{(n)} \leq x) = P(X_1 \leq x, X_2 \leq x, \dots, X_n \leq x) = F^n(x)$$

由于 X_1, X_2, \dots, X_n 独立同分布, $F(x) = \frac{x}{\theta} I_{(0, \theta)}(x)$

$$f_{X_{(n)}}(x) = nF^{n-1}(x)f(x) = n \frac{x^{n-1}}{\theta^{n-1}} \frac{1}{\theta} I_{(0, \theta)}(x)$$

$$\therefore E(X_{(n)}) = \int_{-\infty}^{\infty} x f_{X_{(n)}}(x) dx = \int_0^{\theta} x \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \int_0^{\theta} x^n dx = \frac{n}{n+1} \theta$$

系统偏小

对 $\hat{\theta}_L$ 做修正, $\frac{n+1}{n} X_{(n)}$ 是无偏估计。